

Problem Set 3

Algorithmic Trading

Data Mining - NRC: 2106

Profesor: Erick Ñauñay

Luciana Valdivieso

Nahomi

Mateo Salgado

Josué Cardenas

April 14, 2025

1 Introducción

La toma de decisiones basada en datos se ha convertido en un componente esencial para alcanzar rendimientos competitivos en los mercados financieros. En este proyecto, el objetivo principal fue diseñar, entrenar y evaluar un conjunto de modelos de *machine learning* enfocados en la predicción diaria de movimientos bursátiles, específicamente sobre dos ETFs representativos: el SPY (S&P 500) y el QQQ (Nasdaq 100).

Para abordar este problema, se implementaron diversas técnicas de ensamble y boosting, incluyendo LightGBM, XGBoost, CatBoost y AdaBoost, así como métodos comparativos adicionales como árboles de decisión simples, bosques aleatorios y Gradient Boosting clásico. La estrategia se centró en predecir la dirección del mercado (subida o bajada) día a día, con el fin de maximizar la rentabilidad acumulada de un portafolio de inversión simulado.

Durante el desarrollo, se siguió una metodología estructurada que abarcó la búsqueda y limpieza de datos históricos, la creación de indicadores técnicos relevantes, la construcción de variables derivadas, y una cuidadosa división temporal de los conjuntos de entrenamiento y prueba, evitando el *data leakage*. Adicionalmente, se aplicaron técnicas rigurosas de validación cruzada respetando la naturaleza secuencial de los datos de series temporales y se realizó una optimización de hiperparámetros para reducir el riesgo de sobreajuste.

El resultado final permite no solo comparar el desempeño entre los distintos modelos, sino también construir un portafolio inteligente capaz de asignar de manera dinámica las inversiones en función de las predicciones más confiables, con el objetivo de maximizar el retorno esperado bajo un esquema de control de riesgo.

2 Limpieza de Datos

El proceso de limpieza de datos fue esencial para garantizar la calidad y robustez de los modelos predictivos. Inicialmente, se trabajó con series históricas de precios de los ETFs SPY y QQQ, compuestas por las columnas `Date`, `Open`, `High`, `Low`, `Close`, `Adj Close` y `Volume`.

Se eliminaron registros duplicados basados en la fecha, asegurando una correcta continuidad temporal. Posteriormente, se descartaron observaciones incompletas con valores nulos, principalmente en precios y volumen, ya que podrían sesgar los cálculos de indicadores financieros.

Para prevenir redundancia y alta correlación, se removieron columnas como `Adj Close` y `Close`, preservando únicamente las variables más relevantes y reduciendo así el riesgo de *overfitting*. Se normalizaron las variables numéricas a través de un escalado estándar (`StandardScaler`), incluyendo el volumen de negociación.

Además, se realizaron transformaciones de variables temporales, extrayendo información útil como el día del mes, el día de la semana y el mes correspondiente a cada observación, lo cual enriquece el contexto estacional y cíclico del mercado.

Se creó una nueva variable denominada `daily_return`, que captura el retorno porcentual diario de los activos, indispensable para las simulaciones de inversión realizadas posteriormente.

Con el objetivo de balancear las clases de subida y bajada en los precios, se aplicó una técnica de **oversampling** para igualar la cantidad de observaciones de cada clase, mejorando así la capacidad de generalización de los modelos.

Finalmente, para evitar *data leakage*, todas las transformaciones, cálculos de indicadores técnicos y generación de variables adicionales fueron realizadas utilizando únicamente datos históricos pasados, respetando la naturaleza secuencial de las series de tiempo.

3 Feature Engineering

Luego de la limpieza de datos, se llevó a cabo una etapa exhaustiva de *feature engineering* para enriquecer las variables predictivas y mejorar el desempeño de los modelos.

En primer lugar, se calcularon diversos **indicadores técnicos clásicos** sobre las series de precios, incluyendo:

- **Simple Moving Averages (SMA)** de 10 y 50 días.
- **Relative Strength Index (RSI)** de 14 días.
- **MACD** y su diferencia (`MACD_diff`).
- **Bollinger Bands**.
- **Average True Range (ATR)** de 14 días.
- **Stochastic Oscillator**.
- **ADX (Average Directional Index)** de 14 días.

Posteriormente, se generaron **variables derivadas** como:

- **Price Change** (cambio porcentual diario).
- **Volatility 10 días**.
- **Momentum** de 3, 5, 7 y 10 días.
- **Rolling Mean y Rolling Std** de 3 y 5 días.
- **Returns acumulados** de 1, 3 y 5 días.

Se añadieron **características basadas en volumen**:

- **Volume Change**.
- **Volume SMA 5 días y Volume Ratio**.

Además, se incorporaron **features de calendario** como:

- Día del mes, día de la semana y mes.

Finalmente, se crearon **lags** de variables clave para capturar dependencias temporales y se aplicó **feature selection** para eliminar redundancias.

4 Modelado y Evaluación

4.1 Comparación de Modelos

Modelo		Precision Train	Precision Test	Accuracy Train	Accuracy Test	ROC AUC Train	ROC AUC Test
Decision Tree	SP500	0.6163	0.5238	0.6562	0.4554	0.6446	0.4129
	Nasdaq	0.6087	0.5926	0.6154	0.5093	0.5658	0.5095
Random Forest	SP500	0.6967	0.5588	0.6629	0.4554	0.6646	0.4866
	Nasdaq	0.8128	0.5278	0.7716	0.4352	0.7702	0.4619
AdaBoost	SP500	0.5748	0.5862	0.5915	0.5089	0.5800	0.5062
	Nasdaq	0.5711	0.5833	0.5711	0.5833	0.5000	0.5000
GradientBoosting	SP500	0.7468	0.6097	0.7433	0.5000	0.7420	0.5220
	Nasdaq	0.7003	0.6000	0.7342	0.5462	0.7010	0.5222
LightGBM	SP500	0.7684	0.5957	0.8036	0.5000	0.7994	0.5133
	Nasdaq	0.7165	0.5873	0.7529	0.5185	0.7221	0.5048
XGBoost	SP500	0.5748	0.5921	0.5781	0.5446	0.5706	0.5164
	Nasdaq	0.5711	0.5833	0.5711	0.5833	0.5000	0.5000
CatBoost	SP500	0.6983	0.5000	0.7388	0.4196	0.7322	0.4381
	Nasdaq	0.8182	0.5846	0.8695	0.5185	0.8492	0.5016

Table 1: Comparación de métricas de evaluación en entrenamiento y prueba

Después del análisis, seleccionamos:

- SPY - XGBoost
- QQQ - Gradient Boosting

5 Conclusiones




Figure 1: Evolución del Balance durante la Simulación de Trading

A lo largo del proyecto, logramos diseñar, entrenar y evaluar distintos modelos de aprendizaje automático enfocados en la predicción diaria de movimientos bursátiles. Tras el análisis, el modelo **Gradient Boosting** optimizado para **QQQ (Nasdaq)** y el **XGBoost** optimizado para **SPY (S&P 500)** fueron seleccionados como los mejores.

La simulación final, iniciando con un capital de \$1000, resultó en un balance final de **\$1027.77** tras 30 días de trading, evidenciando un crecimiento moderado pero estable. Se enfrentaron retos como el control del *overfitting* y la validación de datos temporales, pero gracias a un riguroso preprocesamiento, *feature engineering* y selección de modelos, se logró una estrategia de inversión robusta y efectiva.